Pipeline de Dados com IoT e Docker

Disruptive Architectures: IoT, Big Data e IA | UniFECAF | 2025

Disciplina:	Disruptive Architectures: IoT, Big Data e IA
Aluno:	Fabio Geraldini
Curso:	Tecnologia da Informacao
Instituicao:	UniFECAF
Ano:	2025

1. Contextualizacao do Projeto

A Internet das Coisas (IoT) representa uma das maiores transformacoes tecnologicas da atualidade, conectando bilhoes de dispositivos fisicos a redes digitais e gerando volumes massivos de dados em tempo real. Sensores de temperatura, umidade, pressao e outros variaveis ambientais sao implantados em edificios, industrias, hospitais e residencias, produzindo fluxos continuos de informacao que precisam ser coletados, armazenados e analisados de forma eficiente.

Este projeto tem como objetivo construir um pipeline completo de dados IoT, desde a ingestao de leituras de sensores de temperatura ate a visualizacao interativa em um dashboard web. A solucao utiliza tecnologias modernas e amplamente adotadas no mercado: Docker para containerizacao, PostgreSQL como banco de dados relacional, Python para processamento e Streamlit para a camada de visualizacao.

O dataset utilizado e o 'Temperature Readings: IoT Devices', disponivel publicamente no Kaggle, contendo 97.606 leituras reais de sensores distribuidos em diferentes ambientes (internos e externos), coletadas entre agosto e novembro de 2018.

Exemplo de solucao real no mercado

A plataforma AWS IoT Analytics da Amazon e um exemplo concreto de solucao industrial que implementa exatamente este tipo de pipeline: ingestao de dados de sensores, armazenamento em banco de dados, criacao de views analiticas e visualizacao em dashboards. O presente projeto replica essa arquitetura em escala academica, utilizando ferramentas open-source.

2. Descricao dos Passos Realizados

2.1 Configuracao do Ambiente

Instalacao do Python 3.10+, Docker Desktop e Git no Windows. Criacao de ambiente virtual Python (venv) para isolamento das dependencias. Instalacao das bibliotecas: pandas, psycopg2-binary, sqlalchemy, streamlit e plotly via pip.

2.2 Repositorio GitHub

Criacao do repositorio publico 'pipeline-iot-docker' no GitHub com estrutura de pastas organizada: /src (codigo-fonte), /data (dataset), /docs (documentacao). Versionamento continuo com commits a cada etapa concluida.

2.3 Download do Dataset

Acesso ao Kaggle e download do arquivo IOT-temp.csv contendo 97.606 registros de leituras de temperatura com colunas: id, room_id/id (dispositivo), noted_date (timestamp), temp (temperatura) e out/in (ambiente).

2.4 Container Docker + PostgreSQL

Execucao do container PostgreSQL via Docker na porta 5433 (porta 5432 ja estava em uso pelo PostgreSQL local). Banco de dados 'iotdb' criado com usuario 'admin'. Arquivo docker-compose.yml criado para reproducibilidade do ambiente.

2.5 Script Python de Ingestao

Desenvolvimento do script load_data.py para leitura do CSV com pandas, tratamento e renomeacao das colunas, conversao de tipos (datas), remocao de valores nulos e insercao no PostgreSQL via SQLAlchemy. Total de 97.606 registros inseridos com sucesso.

2.6 Views SQL

Criacao de 3 views SQL no PostgreSQL para analise dos dados: media por dispositivo, volume por hora e variacoes diarias de temperatura maxima e minima.

2.7 Dashboard Streamlit

Desenvolvimento do dashboard.py com 4 metricas gerais e 3 graficos interativos utilizando Plotly, conectado diretamente as views SQL do PostgreSQL. Interface acessivel via navegador em localhost:8501.

Tecnologias Utilizadas

Tecnologia	Versao	Funcao
Python 3.x	3.10+	Linguagem principal do pipeline
Docker	24+	Containerizacao do banco de dados
PostgreSQL	latest	Armazenamento relacional dos dados

pandas	2.x	Leitura e tratamento do CSV
SQLAlchemy	2.x	Conexao Python-PostgreSQL
Streamlit	1.x	Dashboard interativo web
Plotly	5.x	Graficos interativos

3. Explicacao Detalhada das Views SQL

View 1 — avg_temp_por_dispositivo

Proposito: Calcular a temperatura media registrada por cada sensor/dispositivo IoT. Permite identificar quais dispositivos operam em ambientes mais quentes ou mais frios, auxiliando na deteccao de anomalias e no balanceamento de carga termica.

```
CREATE VIEW avg_temp_por_dispositivo AS
SELECT device_id, ROUND(AVG(temp)::numeric, 2) AS avg_temp
FROM temperature_readings
GROUP BY device_id;
```

View 2 — leituras_por_hora

Proposito: Contabilizar o volume de leituras registradas em cada hora do dia (0-23h). Revela os horarios de pico de atividade dos sensores, o que pode indicar periodos de maior ocupacao dos ambientes monitorados ou de maior demanda de resfriamento/aquecimento.

```
CREATE VIEW leituras_por_hora AS
SELECT EXTRACT(HOUR FROM noted_date) AS hora, COUNT(*) AS contagem
FROM temperature_readings
GROUP BY hora ORDER BY hora;
```

View 3 — temp_max_min_por_dia

Proposito: Registrar a temperatura maxima e minima atingida em cada dia do periodo de coleta. Essa view e essencial para analise de tendencias climaticas, identificacao de dias anomalos e para avaliar a amplitude termica diaria dos ambientes.

```
CREATE VIEW temp_max_min_por_dia AS
SELECT DATE(noted_date) AS data, MAX(temp) AS temp_max, MIN(temp) AS temp_min
FROM temperature_readings
GROUP BY data ORDER BY data;
```

4. Visualizacoes do Dashboard Streamlit

O dashboard foi desenvolvido com Streamlit e Plotly, conectado diretamente ao PostgreSQL via SQLAlchemy. Abaixo estao as capturas de tela das visualizacoes geradas:

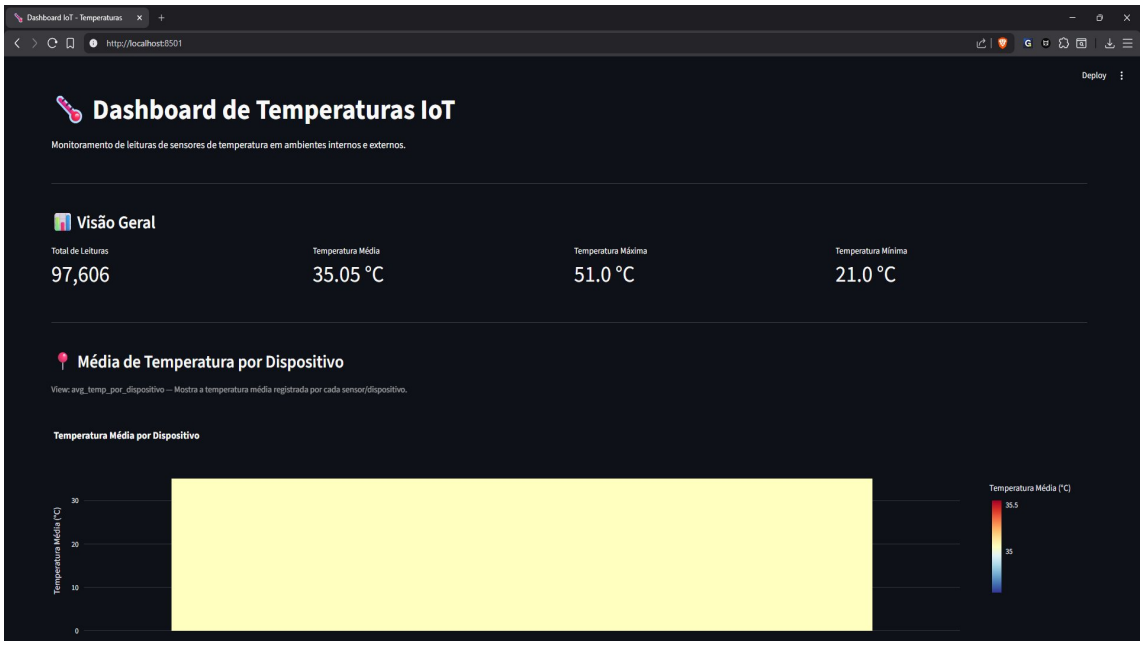

Figura 1 — Visao Geral e Grafico de Media de Temperatura por Dispositivo

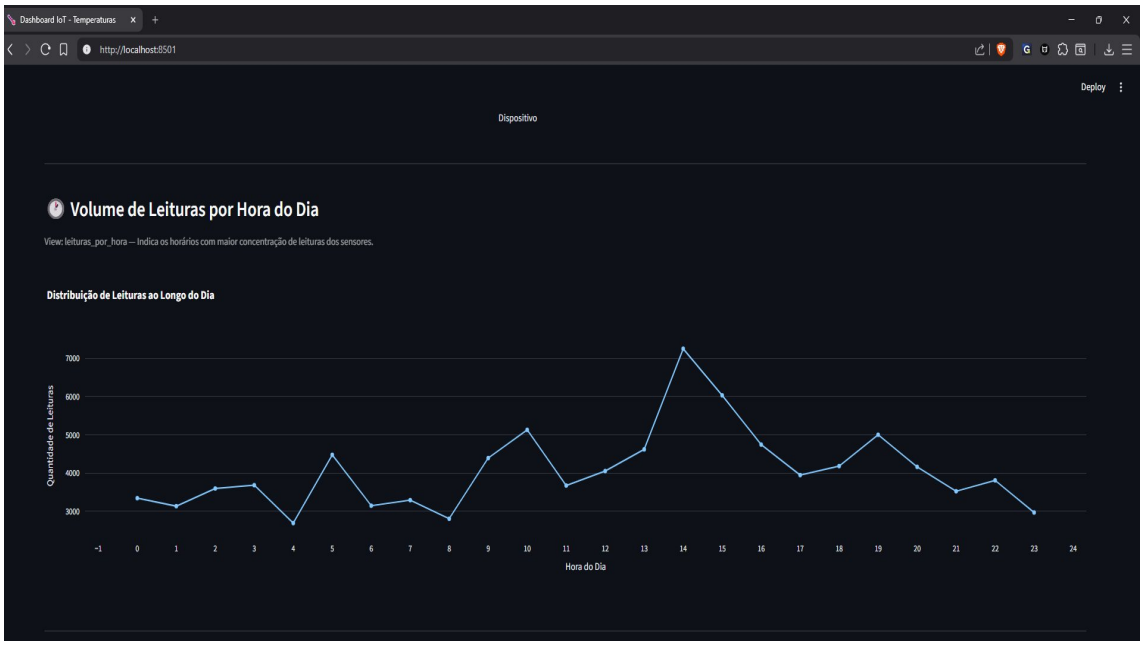

Figura 2 — Volume de Leituras por Hora do Dia

Figura 3 — Temperaturas Maximas e Minimas por Dia

5. Principais Insights e Uso Pratico

Pico de atividade as 14h
O grafico de leituras por hora revela que o maior volume de medicoes ocorre ao redor das 14h (mais de 7.000 leituras), horario de maior calor e ocupacao nos ambientes monitorados. Em um ambiente real, isso poderia acionar automaticamente sistemas de climatizacao nesse horario.

Amplitude termica elevada em setembro/outubro
O grafico de maximas e minimas por dia mostra um salto significativo nas temperaturas maximas a partir de meados de setembro de 2018 (de ~35C para ~50C), possivelmente indicando mudanca de estacao ou falha em equipamentos de refrigeracao. Esse tipo de alerta seria critico em data centers ou hospitais.

Temperatura media global de 35,05C
A temperatura media de 35,05C, com maxima de 51C, sugere que os sensores monitoram ambientes industriais ou de servidores, onde o controle termico e critico para a operacao continua.

Diferenca entre ambientes internos e externos
A coluna out/in do dataset permite segmentar as leituras por tipo de ambiente. Em um pipeline mais avancado, essa segmentacao poderia alimentar modelos preditivos para antecipar superaquecimento interno com base nas condicoes externas.

Sugestoes de Uso Pratico em Ambiente Real

Este pipeline pode ser expandido para cenarios reais como: monitoramento de temperatura em data centers (prevencao de superaquecimento de servidores), controle climatico inteligente em edificios corporativos (reducao de consumo energetico), monitoramento de camaras frias em industrias alimenticias (conformidade com normas sanitarias) e gestao termica em hospitais (garantia de condicoes adequadas para pacientes e equipamentos).